

机器学习与深度学习基础知识整理

7. 类别编码

概念解释：

机器学习模型通常只能接收数值型输入，因此字符串类别变量需要转换为数值形式。常见方法包括标签编码、二值编码和独热编码。

在本文中的体现：

本文将燃料类型 `type_fuel` 中的 `P` 和 `D` 分别映射为 0 和 1。由于该字段只有两个类别，二值编码与独热编码在信息表达上基本等价，但二值编码更简洁。

答辩表述：

本文对燃料类型使用二值编码，是因为该字段只有汽油和柴油两个有效类别，不需要额外扩展维度，能够简化输入特征。

8. 特征工程

概念解释：

特征工程是指根据原始数据构造更有表达力、更适合模型学习的输入变量。好的特征工程可以让模型更容易捕捉数据规律。

在本文中的体现：

本文对日期字段进行了特征工程处理。例如根据出生日期构造投保人年龄，根据驾照签发日期构造驾龄，根据车辆注册年份构造车龄，根据合同日期构造保单持续时间。

作用说明：

原始日期字符串无法直接输入神经网络，而年龄、驾龄、车龄、保单年限等派生特征具有明确的业务含义，更有利于模型学习理赔风险规律。

答辩表述：

本文没有直接使用原始日期字符串，而是将日期转化为年龄、驾龄、车龄、保单持续时间等具有业务意义的数值特征，从而提高模型对风险因素的学习能力。

9. StandardScaler 标准化

概念解释：

`StandardScaler` 是 scikit-learn 中常用的标准化工具。它通过减去均值、除以标准差，把特征转换为均值为 0、标准差为 1 的分布。公式可以表示为：

$$z = (x - \mu) / \sigma$$

其中， x 是原始特征值， μ 是训练集中该特征的均值， σ 是训练集中该特征的标准差。

在本文中的体现：

本文使用 `sklearn.preprocessing.StandardScaler` 对输入特征进行标准化处理。标准化参数只在训练集上拟合，然后应用到验证集、测试集和推理数据中。

为什么需要标准化：

车险数据中不同特征的量纲差异很大，例如车辆价值可能是几万元，年龄可能是几十，燃料类型只有 0/1。如果不标准化，数值范围较大的特征可能在训练中占据过大影响，导致模型收敛慢或不稳定。

重要原则：

标准化只能用训练集计算均值和标准差，不能把验证集或测试集也拿来拟合 `scaler`。否则测试集信息会提前进入训练流程，造成数据泄漏。

答辩表述：

本文使用 `StandardScaler` 是为了消除不同特征量纲差异，使神经网络训练更加稳定。标准化参数只在训练集上拟合，再应用到验证集和测试集，这样可以避免数据泄漏。

三、深度学习模型结构基础

13. 多层感知机 MLP

概念解释：

多层感知机（Multi-Layer Perceptron，MLP）是一种典型的前馈神经网络，由输入层、若干隐藏层和输出层组成。每一层通过线性变换和非线性激活函数对输入进行特征变换。

基本形式：

1 | 输入特征 → 全连接层 → 激活函数 → 隐藏层 → 输出层

在本文中的体现：

本文使用 MLP 作为车险理赔预测模型的基础结构。输入为经过标准化的保单特征向量，输出为是否发生理赔的预测得分。

为什么适合本文：

本文使用的是结构化表格数据，而 MLP 对表格型数值特征具有较好的适用性，结构清晰，实现简单，便于与系统部署结合。

答辩表述：

本文选择 MLP，是因为车险数据主要是结构化表格特征，MLP 能够通过多层非线性映射学习特征之间的复杂关系，同时结构相对简单，便于训练和部署。

14. 全连接层 Linear

概念解释：

全连接层是神经网络中最基本的结构之一，它对输入向量进行线性变换，即每个输出神经元都与上一层所有输入神经元相连。

数学形式：

1 | $y = wx + b$

其中，`w` 是权重矩阵，`b` 是偏置项，`x` 是输入向量。

在本文中的体现：

本文的输入投影层、残差块内部映射层和分类头都使用了全连接层。全连接层负责把原始特征映射到隐藏表示空间，并逐步提取用于理赔分类的特征。

答辩表述：

全连接层的作用是对输入特征进行线性组合，学习不同特征之间的权重关系，是 MLP 模型进行特征表示学习的基础。

15. 隐藏层与隐藏维度

概念解释：

隐藏层是输入层和输出层之间的中间计算层，用于提取更高层次的特征表示。隐藏维度表示隐藏层输出向量的长度，也可以理解为模型内部表示空间的大小。

在本文中的体现：

本文主干网络的隐藏层宽度依次为 128、256、256、128 和 128，构成“先扩宽、再深化、后收窄、再精炼”的结构。

作用说明：

隐藏维度过小可能导致模型表达能力不足，隐藏维度过大则可能增加过拟合和计算成本。本文通过残差块和沙漏型宽度设计，在表达能力和稳定性之间做平衡。

16. 激活函数

概念解释：

激活函数为神经网络引入非线性能力。如果没有激活函数，多层神经网络本质上仍然只是线性变换的叠加，难以学习复杂关系。

在本文中的体现：

本文使用 GELU 激活函数。GELU 是深度学习中常用的非线性函数，能够在保留平滑性的同时增强模型对非线性关系的表达能力。

作用说明：

车险理赔风险与车辆属性、驾驶经验、历史理赔等因素之间往往不是简单线性关系，因此需要激活函数帮助模型学习复杂非线性模式。

答辩表述：

激活函数的作用是引入非线性表达能力，使模型能够学习复杂的风险模式。本文采用 GELU，是为了提升模型在深层结构中的平滑性和非线性拟合能力。

17. GELU 激活函数

概念解释：

GELU (Gaussian Error Linear Unit) 是一种平滑的激活函数。相比 ReLU 直接把负值截断为 0，GELU 会根据输入大小以更平滑的方式保留或抑制信息。

在本文中的体现：

本文在输入投影层、残差块和分类头中均使用 GELU。它与 LayerNorm、Dropout、残差连接共同构成稳定的深层 MLP 结构。

作用说明：

GELU 可以增强模型对非线性特征交互的表达能力，并使训练过程更平滑，适合与深层网络结构配合使用。

18. Logit 与 Sigmoid

概念解释：

Logit 是模型在经过 Sigmoid 函数之前输出的原始分数。Sigmoid 函数可以把任意实数映射到 0 到 1 之间，因此常用于二分类概率输出。

公式：

$$p = \text{sigmoid}(\text{logit}) = 1 / (1 + \exp(-\text{logit}))$$

在本文中的体现：

本文模型输出的是一个 logit，最终通过 `sigmoid(logit)` 得到发生理赔的概率，再根据自动搜索得到的分类阈值判断是否为有理赔风险。

为什么训练时不直接 Sigmoid：

本文使用 `BCEWithLogitsLoss`，该损失函数内部已经将 Sigmoid 与二元交叉熵结合起来，数值上更稳定。因此模型训练时不需要在网络内部显式调用 Sigmoid。

答辩表述：

模型输出的是 logit，推理时通过 Sigmoid 转为理赔概率；训练时使用 `BCEWithLogitsLoss`，是因为它将 Sigmoid 和交叉熵合并计算，能够提高数值稳定性。

19. Backbone 主干网络

概念解释：

Backbone 指模型中负责主要特征提取的主体网络。它把原始输入特征转化为更高层、更抽象的表示，供后续分类头使用。

在本文中的体现：

本文的 Backbone 由输入投影层和多个残差块组成，负责将结构化保单特征映射为 128 维高层表示向量。

作用说明：

主干网络越能提取有效特征，分类头越容易做出准确判断。本文的主干网络通过残差连接、LayerNorm、GELU 和 Dropout 增强表达能力和训练稳定性。

20. 分类头 Classification Head

概念解释：

分类头是接在主干网络之后的输出模块，负责把主干网络提取到的特征表示转化为最终分类结果。

在本文中的体现：

本文分类头将 128 维共享表示压缩到 32 维，再经过 LayerNorm、GELU、Dropout 和线性层输出一个标量 logit，用于判断是否发生理赔。

作用说明：

主干网络负责学习通用风险表征，分类头负责根据这些表征做出二分类决策。

21. 残差连接

概念解释：

残差连接是指在网络中引入一条“捷径分支”，把输入直接加到后续层的输出上。其基本形式为：

1 | 输出 = F(x) + x

如果输入维度和输出维度不同，则需要先通过线性投影把维度对齐。

在本文中的体现：

本文在 MLP 基础上引入了残差块。每个残差块中，输入一方面经过全连接层、LayerNorm、GELU 和 Dropout 等主分支进行变换，另一方面通过 shortcut 分支保留原始信息，最后两者相加。

作用说明：

残差连接的主要作用包括：

- 1. 改善梯度传播，缓解深层网络训练困难；
- 2. 保留输入中的原始有效信息，避免多层变换导致信息丢失；
- 3. 在网络宽度变化时，通过投影分支实现维度对齐；
- 4. 使模型更容易学习“在原有特征基础上的修正量”，而不是每一层都重新学习完整映射。

答辩表述：

本文引入残差连接，是为了缓解深层 MLP 中梯度传播受阻和信息损失问题。残差结构能够让输入信息通过捷径分支直接传递到后续层，使模型训练更加稳定。

22. 残差块 ResidualBlock

概念解释：

残差块是由主分支和捷径分支组成的网络单元。主分支负责特征变换，捷径分支负责保留输入信息，两者相加后再输出。

在本文中的结构：



作用说明：

ResidualBlock 是本文优化后 MLP 的核心结构单元。它既增强了模型表达能力，也提高了训练稳定性。

23. LayerNorm 层归一化

概念解释：

LayerNorm 是一种归一化方法，它通常在单个样本的特征维度上进行归一化，使中间特征分布更加稳定。

在本文中的体现：

本文在输入投影层、残差块和分类头中都使用了 LayerNorm。它与 StandardScaler 的区别在于：StandardScaler 是数据预处理阶段对输入特征做标准化，而 LayerNorm 是神经网络内部对中间表示做归一化。

作用说明：

LayerNorm 可以缓解网络中间层特征分布波动，提高训练稳定性，尤其适合深层网络结构。

答辩表述：

StandardScaler 作用于模型输入，LayerNorm 作用于网络内部隐藏表示。本文使用 LayerNorm 是为了稳定深层 MLP 中每一层的特征分布，从而提高收敛稳定性。

24. Dropout

概念解释：

Dropout 是一种常用的深度学习正则化方法。训练时，它会以一定概率随机“丢弃”部分神经元，使这些神经元暂时不参与当前前向传播和参数更新；推理时则关闭 Dropout，使用完整网络进行预测。

在本文中的体现：

本文在输入投影层、残差块和分类头中使用 Dropout，主干部分的 Dropout 取值为 0.25。分类头中还结合多次前向计算取平均，以增强预测稳定性。

作用说明：

Dropout 的主要作用包括：

1. 防止模型过度依赖某些特定神经元；
2. 降低过拟合风险；
3. 提高模型泛化能力；
4. 在训练阶段形成类似多个子网络集成的效果。

为什么训练损失可能高于验证损失：

训练时 Dropout 开启，部分神经元被随机丢弃，模型表达能力被临时削弱，因此训练损失可能偏高；验证时 Dropout 关闭，使用完整网络进行评估，因此验证损失可能略低。

答辩表述：

Dropout 的作用是随机失活部分神经元，减少模型对局部特征的过度依赖，从而抑制过拟合。训练时开启 Dropout，验证和推理时关闭 Dropout，因此有时会出现验证损失低于训练损失的情况。

25. 沙漏型网络结构

概念解释：

沙漏型结构是指网络维度先升高再降低，类似“扩张—压缩”的过程。升维阶段增强表示能力，降维阶段压缩冗余信息。

在本文中的体现：

本文主干网络宽度从 128 升至 256，再从 256 降回 128，形成“先扩宽、再深化、后收窄、再精炼”的结构。

作用说明：

这种结构先在较高维空间中学习复杂特征交互，再通过降维压缩去除冗余或噪声信息，最终得到更紧凑的风险表征。

答辩表述：

沙漏型结构的设计目的是先扩大特征表示空间，增强模型对复杂非线性关系的学习能力，再通过降维压缩冗余信息，使最终表示兼具判别性和紧凑性。

四、训练目标与损失函数基础

26. 损失函数

概念解释：

损失函数用于衡量模型预测结果与真实标签之间的差异。训练过程就是不断最小化损失函数的过程。

在本文中的体现：

本文使用带正类权重的二元交叉熵损失函数，即 `BCEWithLogitsLoss(pos_weight=...)`。它适用于二分类任务，并且能够结合正类权重处理类别不平衡问题。

答辩表述：

损失函数为模型提供优化目标。本文使用加权二元交叉熵，是因为任务是二分类，同时数据中理赔样本少于非理赔样本，需要提高模型对正类样本的关注度。

27. 二元交叉熵 BCE

概念解释：

二元交叉熵 (Binary Cross Entropy, BCE) 是二分类任务常用损失函数。它会惩罚预测概率与真实标签之间的差异：真实标签为 1 时，希望模型预测概率接近 1；真实标签为 0 时，希望预测概率接近 0。

在本文中的体现：

本文的目标是预测是否发生理赔，因此适合使用二元交叉熵作为基本损失函数。

作用说明：

BCE 能够直接优化二分类概率输出，使模型学习“有理赔”和“无理赔”之间的判别边界。

28. BCEWithLogitsLoss

概念解释：

`BCEWithLogitsLoss` 是 PyTorch 中常用的二分类损失函数，它把 Sigmoid 和 BCE 合并在一起计算。相比先手动 Sigmoid 再计算 BCE，这种方式具有更好的数值稳定性。

在本文中的体现：

本文模型输出 logit，而不是直接输出概率，训练时使用 `BCEWithLogitsLoss` 计算损失。推理时再通过 Sigmoid 将 logit 转为概率。

答辩表述：

本文使用 `BCEWithLogitsLoss`，是因为它能直接接收 logit，并在内部完成 Sigmoid 和二元交叉熵计算，避免数值溢出和精度不稳定问题。

30. 标签平滑

概念解释：

标签平滑是指把硬标签 0 或 1 适度软化，例如把 1 调整为 0.95，把 0 调整为 0.05。这样可以防止模型对训练标签过度自信。

在本文中的体现：

本文在加权二元交叉熵中加入标签平滑，用于降低过拟合风险。

作用说明：
真实业务数据中可能存在噪声或边界样本，标签平滑可以让模型不要过分绝对地拟合训练标签，从而提升泛化能力。

答辩表述：
标签平滑是一种轻量级正则化方法，可以防止模型对训练样本标签过度自信，降低过拟合风险。

31. 正则化

概念解释：
正则化是指通过增加约束或扰动，防止模型过度拟合训练集，从而提升模型在未知数据上的泛化能力。常见正则化方法包括 Dropout、权重衰减、早停、标签平滑等。

在本文中的体现：
本文使用了多种正则化策略：

- Dropout：随机失活神经元；
- AdamW 的权重衰减：限制参数过大；
- Early Stopping：验证集性能不再提升时停止训练；
- 标签平滑：防止模型对标签过度自信；
- LayerNorm 和残差连接虽然不完全等同于正则化，但能增强训练稳定性。

作用说明：
车险数据存在类别不平衡和噪声，深度模型如果训练过久或参数过多，容易记住训练集中的局部噪声。正则化可以降低这种风险。

答辩表述：
正则化的核心作用是抑制过拟合，提高泛化能力。本文中 Dropout、权重衰减、标签平滑和 Early Stopping 都起到了正则化作用。

五、优化器与训练策略基础

32. 优化器

概念解释：
优化器用于根据损失函数的梯度更新模型参数。不同优化器的更新方式不同，会影响训练速度、稳定性和最终效果。

在本文中的体现：
本文选择 AdamW 优化器。AdamW 是 Adam 的改进版本，将权重衰减与梯度更新解耦，更适合深度神经网络训练。

答辩表述：
优化器的作用是根据损失函数计算出的梯度更新模型参数。本文使用 AdamW，是因为它兼具自适应学习率和解耦权重衰减，有助于提高训练稳定性和泛化能力。

33. Adam 优化器

概念解释：

Adam 是一种自适应学习率优化器，它同时利用梯度的一阶矩估计和二阶矩估计，为不同参数动态调整学习率。

作用说明：

相比普通梯度下降，Adam 通常收敛更快，对不同尺度参数更稳健。

34. AdamW 优化器

概念解释：

AdamW 是 Adam 的改进版本。它将权重衰减从梯度更新中分离出来，使权重衰减真正发挥正则化作用。

在本文中的体现：

本文选择 AdamW 作为优化器，用于提升深度 MLP 模型训练的稳定性 and 泛化能力。

为什么比 Adam 更合适：

在传统 Adam 中，L2 正则化与自适应学习率耦合，可能削弱正则化效果。AdamW 把参数更新和权重衰减分开处理，使正则化更直接。

答辩表述：

AdamW 相比 Adam 的主要优势是解耦权重衰减，使权重衰减不再受自适应学习率干扰，从而获得更稳定、更有效的正则化效果。

35. 权重衰减

概念解释：

权重衰减是一种正则化方法，它会在训练过程中限制模型参数过大。参数过大时，模型容易对训练数据中的局部噪声过度敏感。

在本文中的体现：

本文通过 AdamW 实现解耦权重衰减，以提升模型泛化能力。

答辩表述：

权重衰减的作用是限制模型权重过大，降低过拟合风险。AdamW 中的权重衰减与梯度更新解耦，因此正则化效果更稳定。

36. 学习率

概念解释：

学习率控制每次参数更新的步长。学习率过大可能导致训练震荡甚至不收敛，学习率过小则会导致训练过慢或陷入局部区域。

在本文中的体现：

本文结合 AdamW 使用 Cosine Warmup 学习率调度策略，使训练前期稳定启动，中后期平滑收敛。

答辩表述：

学习率决定模型每次参数更新的幅度。本文使用学习率调度，是为了避免训练初期更新过猛，同时在中后期逐渐减小学习率以获得更稳定的收敛效果。

37. Cosine Warmup 学习率调度

概念解释：

Cosine Warmup 通常包括两个阶段：前期 Warmup 逐步增大学习率，使训练稳定启动；后期使用余弦退火逐渐降低学习率，使模型平滑收敛。

在本文中的体现：

本文训练阶段先使用 `LinearLR` 进行线性预热，再切换到 `CosineAnnealingLR` 进行余弦退火。

作用说明：

训练初期模型参数尚未稳定，如果学习率过大，容易造成训练震荡。Warmup 可以缓解这一问题；余弦退火则有助于训练后期细致搜索较优参数区域。

答辩表述：

Cosine Warmup 的作用是前期稳定启动、后期平滑收敛。对于类别不均衡且特征维度较多的车险数据，这种策略可以提高训练稳定性。

38. Early Stopping 早停

概念解释：

Early Stopping 是一种基于验证集性能的训练终止策略。当模型在验证集上的指标长期没有提升时，提前停止训练，避免继续拟合训练集噪声。

在本文中的体现：

本文使用 AUC 作为早停监控指标。当验证集 AUC 不再提升时，停止训练并保留泛化能力较好的模型参数。

作用说明：

训练集损失持续下降不一定代表模型泛化能力提升。早停可以防止模型在训练后期过拟合。

答辩表述：

Early Stopping 是一种基于验证集反馈的正则化方法。本文使用 AUC 监控早停，是因为 AUC 更能反映模型整体排序能力，并且对类别不平衡较稳健。

39. 梯度裁剪

概念解释：

梯度裁剪是指当梯度过大时，将其限制在一定范围内，防止参数更新过猛。

在本文中的体现：

本文训练流程中启用了梯度裁剪，以进一步提升训练过程的数值稳定性。

作用说明：

在深层网络训练中，梯度有时可能突然变得很大，导致损失震荡或训练不稳定。梯度裁剪可以缓解这种问题。

答辩表述：

梯度裁剪用于限制过大的梯度，防止模型参数更新过猛，从而提高训练稳定性。

40. AMP 混合精度训练

概念解释：

AMP (Automatic Mixed Precision) 混合精度训练是指在训练中结合使用 16 位和 32 位浮点数，以提高训练速度并减少显存占用，同时保持基本的数值精度。

在本文中的体现：

本文训练流程启用了 AMP 混合精度，以提升训练效率和数值稳定性。

答辩表述：

AMP 混合精度训练可以在保证模型精度的同时提高训练效率，减少计算资源消耗，适合深度学习模型训练过程。

41. Epoch 与 Batch

概念解释：

Epoch 表示模型完整遍历一次训练集；Batch 表示每次参数更新时使用的一小批样本。

作用说明：

使用 Batch 训练可以降低单次计算压力，并通过小批量梯度更新提高训练效率。多个 Epoch 训练则使模型反复学习训练数据中的规律。

答辩表述：

Batch 是一次参数更新使用的样本批次，Epoch 是完整遍历一次训练集。深度学习通常通过多个 Epoch 的小批量训练逐步优化模型参数。

六、类别不平衡与阈值优化基础

44. 分类阈值

概念解释：

二分类模型通常输出一个概率值，需要设定阈值把概率转化为类别。例如阈值为 0.5 时，概率大于等于 0.5 判为正类，否则判为负类。

在本文中的体现：

本文没有固定使用 0.5 阈值，而是在验证集上从 0.05 到 0.95 生成多个候选阈值，并选择使目标指标更优的阈值。

为什么不固定 0.5：

在类别不平衡任务中，0.5 阈值未必最适合业务目标。车险风控通常更关注漏判高风险保单的问题，因此需要根据 Recall 和 F1/Fβ 指标选择更合适的阈值。

答辩表述：

本文使用自动阈值搜索，是因为固定 0.5 阈值无法适应类别不平衡和业务目标。通过验证集搜索，可以在召回率和精确率之间取得更合理的平衡。

45. 自动阈值搜索

概念解释：
自动阈值搜索是指在验证集上尝试多个候选阈值，计算不同阈值下的 Precision、Recall、F1 或 $F\beta$ ，然后选择最符合业务目标的阈值。

在本文中的体现：
本文每个 epoch 后在验证集上进行阈值搜索，候选阈值范围为 0.05 到 0.95，并结合 `threshold_beta=1.3` 和 `threshold_min_recall=0.830` 更偏重召回率。

作用说明：
自动阈值搜索将“模型排序能力”和“最终业务判定规则”分离。模型负责输出风险概率，阈值搜索负责根据业务目标确定判定边界。

答辩表述：
自动阈值搜索能够根据验证集表现动态选择分类边界，使模型输出更加符合车险风控中尽量减少高风险保单漏判的需求。

46. 加权损失与阈值搜索的关系

概念解释：
加权损失会让模型训练时更重视正类样本，但也可能使预测概率整体向正类倾斜。如果仍然使用固定 0.5 阈值，可能导致假阳性过多。

在本文中的体现：
本文消融实验说明，加权损失需要配合自动阈值搜索。加权损失提高模型对少数类的关注，而阈值搜索负责校正决策边界。

答辩表述：
加权损失主要改变模型对少数类的关注程度，阈值搜索则调整最终分类边界。两者配合使用，才能在召回率和精确率之间取得更合理的平衡。

七、模型评估指标基础

47. 混淆矩阵

概念解释：
混淆矩阵是二分类任务中分析预测结果的基础。它包括四种情况：

名称	含义	在本文中的例子
TP 真正例	实际有理赔，模型也预测有理赔	正确识别高风险保单
FP 假正例	实际无理赔，模型预测有理赔	正常保单被误报为高风险
TN 真负例	实际无理赔，模型也预测无理赔	正确识别低风险保单
FN 假负例	实际有理赔，模型预测无理赔	高风险保单被漏判

作用说明：
Precision、Recall、F1 等指标都可以由混淆矩阵计算得到。

48. Precision 精确率

概念解释:

Precision 表示模型预测为正类的样本中，有多少是真正的正类。

$$1 \quad \text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

在本文中的含义:

在被模型判定为“有理赔风险”的保单中，真正发生理赔的比例。

业务解释:

Precision 越高，说明误报越少；Precision 低则意味着很多正常保单被错误标记为高风险。

49. Recall 召回率

概念解释:

Recall 表示所有真实正类样本中，有多少被模型成功识别出来。

$$1 \quad \text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

在本文中的含义:

所有真实发生理赔的保单中，被模型识别为有理赔风险的比例。

业务解释:

Recall 越高，漏判越少。车险风控中通常比较重视 Recall，因为漏掉高风险保单可能带来更大损失。

50. F1 Score

概念解释:

F1 Score 是 Precision 和 Recall 的调和平均值，用于综合衡量模型对正类的识别能力。

$$1 \quad \text{F1} = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$$

在本文中的体现:

本文使用 F1 作为重要评估指标，并将其用于阈值搜索过程。

作用说明:

只看 Precision 可能漏掉很多高风险样本，只看 Recall 可能误报过多。F1 能够同时考虑误报和漏判。

答辩表述:

F1 兼顾精确率和召回率，适合评价类别不平衡场景下模型对理赔样本的综合识别能力，因此本文将其作为重要评估指标和阈值选择依据。

51. F β Score

概念解释:

F β 是 F1 的推广形式，可以通过参数 β 调整 Precision 和 Recall 的相对重要性。 $\beta > 1$ 时更重视 Recall， $\beta < 1$ 时更重视 Precision。

在本文中的体现：

本文阈值搜索中设置 `threshold_beta=1.3`，说明相比标准 F1，更加重视召回率。

业务解释：

车险风控中漏判高风险保单的代价通常较高，因此可以适当提高 Recall 权重。

答辩表述：

本文使用 $\beta=1.3$ 的 $F\beta$ 指标，是为了在阈值搜索中更偏重召回率，使模型更符合风控场景中减少漏判的业务目标。

52. AUC-ROC

概念解释：

AUC-ROC 是衡量二分类模型排序能力的重要指标。ROC 曲线以假正率 FPR 为横轴、真正率 TPR 为纵轴，AUC 是 ROC 曲线下的面积。

概率意义：

AUC 可以理解为：随机抽取一个正样本和一个负样本，模型把正样本预测得分排在负样本前面的概率。

在本文中的体现：

本文使用 AUC 评估模型整体区分能力，并使用 AUC 作为 Early Stopping 的监控指标。

为什么适合类别不平衡：

AUC 不依赖某一个固定阈值，更关注整体排序能力，因此在类别不平衡场景下比 Accuracy 更稳健。

答辩表述：

AUC 衡量的是模型对正负样本的整体排序能力，不依赖固定阈值。本文使用 AUC 作为早停指标，是为了避免阈值波动影响对模型本身能力的判断。

53. PR-AUC

概念解释：

PR-AUC 是 Precision-Recall 曲线下的面积，主要反映模型在不同阈值下对正类样本的识别能力。

在本文中的意义：

在类别不平衡任务中，PR-AUC 往往比 ROC-AUC 更关注少数类表现，因此可以作为补充指标。

答辩表述：

PR-AUC 更关注正类识别能力，适合作为类别不平衡任务中 AUC-ROC 的补充评价指标。

54. Accuracy 准确率

概念解释：

Accuracy 表示所有样本中预测正确的比例。

1

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

为什么本文不能只看 Accuracy：

由于本文中非理赔样本占多数，模型即使大量预测“无理赔”，也可能获得较高准确率，但这并不代表它能够识别理赔风险。

答辩表述：

本文没有只使用 Accuracy，是因为数据存在类别不平衡。仅看准确率可能掩盖模型对少数类理赔样本识别能力不足的问题。

56. 消融实验

概念解释：

消融实验是指在保持其他条件不变的情况下，去掉或替换某个模块，观察模型性能变化，以判断该模块是否有效。

在本文中的体现：

本文进行了加权损失与自动阈值搜索对照实验，以及不同网络结构对照实验，用于分析各策略对模型性能贡献。

作用说明：

消融实验可以证明模型改进不是随意堆叠技术，而是每项设计都有实验依据。

答辩表述：

消融实验用于验证单个策略的贡献。本文通过对比加权损失、固定阈值、自动阈值搜索和不同网络结构，说明优化策略对模型性能具有实际作用。

八、模型部署与系统集成相关基础

59. FastAPI 模型服务

概念解释：

FastAPI 是 Python 中常用的 Web API 框架，适合把训练好的机器学习模型封装成在线预测服务。

在本文中的体现：

本文通过 FastAPI 将训练好的 MLP 模型部署为独立预测服务，并与 Spring Boot 业务系统进行集成。

作用说明：

模型服务与业务系统解耦后，模型可以独立更新和维护，不需要频繁修改主体业务系统。

答辩表述：

本文使用 FastAPI 封装模型推理接口，使深度学习模型能够作为独立服务对外提供预测能力，从而降低模型更新对业务系统的影响。

61. 在线推理

概念解释：

在线推理是指用户提交一条或一批新数据后，系统实时调用模型返回预测结果。

在本文中的体现：

用户可以选择已有保单或手动输入特征信息进行预测，系统返回理赔概率、预测标签和风险等级。

答辩表述：

本文通过 FastAPI 提供在线推理接口，业务系统将保单特征传给模型服务，模型返回理赔概率和风险等级，实现了算法模型与业务系统的集成。

62. 局部消融解释

概念解释：

局部消融解释是指针对某一次预测，逐个改变或移除某些特征，观察预测结果变化，从而分析哪些特征对本次预测影响较大。

在本文中的体现：

本文预测模块会给出主要风险提升因素和风险缓释因素，用于辅助用户理解预测结果。

作用说明：

深度学习模型可解释性较弱，局部消融解释可以为业务人员提供直观参考，帮助其理解为什么某张保单被判定为高风险。

答辩表述：

局部消融解释通过观察单个特征变化对预测概率的影响，提取主要风险提升因素和风险缓释因素，从而增强模型结果的业务可理解性。

九、论文中容易被问到的答辩问题与回答口径

问题1：为什么不用普通 MLP，而要加入残差连接？

普通 MLP 在层数加深后可能出现梯度传播困难、收敛不稳定和信息丢失问题。残差连接通过 shortcut 分支保留输入信息，使模型更容易训练，也能提高深层结构的稳定性。因此，本文在基础 MLP 上加入残差块，以增强模型表达能力并缓解训练困难。

问题2：Dropout 的作用是什么？

Dropout 是一种正则化方法，训练时随机失活部分神经元，防止模型过度依赖某些局部特征，从而降低过拟合风险。推理时 Dropout 关闭，使用完整网络进行预测。

问题3：StandardScaler 和 LayerNorm 有什么区别？

StandardScaler 是数据预处理方法，作用于模型输入特征，在训练前根据训练集均值和标准差进行标准化。LayerNorm 是神经网络内部的归一化层，作用于隐藏层表示，用于稳定深层网络训练。二者作用位置不同，但都能提高训练稳定性。

问题4：为什么使用 BCEWithLogitsLoss？

因为本文是二分类任务，模型输出 logit。BCEWithLogitsLoss 将 Sigmoid 和二元交叉熵合并计算，比先 Sigmoid 再计算 BCE 更稳定，也更适合 PyTorch 中的二分类训练流程。

问题5：pos_weight 是干什么的？

pos_weight 用于提高正类样本在损失函数中的权重。本文理赔样本少于非理赔样本，若不加权，模型容易偏向预测多数类“无理赔”。加入 pos_weight 可以让模型更加关注理赔样本，提高少数类识别能力。

问题6：为什么不直接用 0.5 作为分类阈值？

因为本文数据存在类别不平衡，固定 0.5 阈值未必能兼顾 Precision 和 Recall。车险风控中漏判高风险保单的代价较高，因此本文在验证集上自动搜索阈值，并结合 F β 和召回率约束选择更符合业务目标的阈值。

问题7：为什么早停监控指标选择 AUC？

AUC 衡量模型对正负样本的整体排序能力，不依赖固定分类阈值。本文训练过程中会进行自动阈值搜索，如果用 F1 或 Recall 作为早停指标，可能会受到阈值变化影响。因此选择 AUC 作为早停指标更稳定。

问题8：为什么使用 AdamW 而不是 Adam？

AdamW 在 Adam 的基础上将权重衰减与梯度更新解耦，使权重衰减发挥更稳定的正则化作用。对于深度神经网络，AdamW 通常能带来更好的泛化能力和训练稳定性。

问题9：为什么训练损失可能高于验证损失？

训练时 Dropout 开启，部分神经元随机失活，模型表达能力被临时削弱，因此训练损失可能偏高。验证时 Dropout 关闭，使用完整网络评估，因此验证损失可能低于训练损失。这种现象在使用 Dropout 的模型中是合理的。

问题10：为什么本文不能只看准确率？

因为理赔样本占比较低，模型即使把大多数样本预测为无理赔，也可能获得较高准确率，但这无法满足风险识别需求。因此本文更关注 AUC、Precision、Recall、F1 等指标，尤其关注对理赔样本的识别能力。