

基于深度学习的车险理赔预测系统设计与实现

——答辩稿

Slide 1: 封面

各位老师好，我是来自数据科学与大数据技术专业的钱信宇，我的毕业设计题目是"基于深度学习的车险理赔预测系统设计与实现"，指导教师是丁晓宇老师。接下来我将从研究目标、具体实现、创新与难点三个方面来介绍我的毕业设计工作。

Slide 2: 研究目标与设计概要

我的研究目标是设计并实现一套车险理赔预测系统。整个工作可以分为两条主线：**业务系统构建**和**预测模型构建**。

一、三层架构业务系统

在系统方面，我构建了前后端分离架构的体系。前端提供交互式管理界面和数据可视化能力。后端实现对保单信息、理赔记录、车辆信息三大核心业务数据的增删改查管理与多维度统计分析。预测服务层将训练好的深度学习模型部署为独立的推理服务，数据层则使用 MySQL 数据库进行持久化存储。

二、深度学习预测模型

在模型方面，我基于多层感知机构建了一个二分类模型，目标任务是预测某份保单在当前年度是否会发生理赔。模型的输出是该保单发生理赔的概率值，以及基于最优分类阈值给出的 0/1 预测标签。

三、业务闭环

这套系统中用户可以管理保单数据，发起理赔风险预测，这样就实现了从"数据管理 到 模型预测 再到 结果分析"的完整业务闭环，为车险行业理赔风控的数字化转型提供了一套可落地的原型方案。

Slide 3: 模型设计

关于模型设计，主要分为以下四个部分：

在数据处理与特征工程部分

由于数据集中存在三个具有缺失值的字段，我根据各自的业务含义分别采取了不同的处理策略：

第一个是 **保单退保日期** 字段，由于退保行为本身往往与最终的理赔结果存在因果关系，所以直接丢弃该字段。

第二个是 **车辆长度** 字段，由于同一种车辆类型的车身长度分布相近，我按照车辆类型分组，用同一组内的中位数进行填充。

第三个是 **燃料类型** 字段，原始数据中仅有汽油和柴油两种类型，同样按照车辆类型分组，用同一组内的众数填充。

此外，保险数据中存在多个右偏严重的数值字段，我对这些字段统一执行了 99.9 分位截断

由于原始数据集中包含五个日期类字段，以字符串形式存储，神经网络无法直接处理字符串输入。我的处理策略分为两步：

第一步，设定参考日期锚点。将参考日期统一设定为每条保单的"合同开始日期"，

第二步，提取了四个核心派生特征，分别是：

- 驾龄
- 投保人年龄
- 保单年限
- 车龄

这四种特征都具有明确的业务含义。

在模型结构设计部分

从网络结构上看，模型由输入投影层、残差网络和分类输出头三个部分构成，前两个部分共同构成主干网络。

其中，输入投影层将原始特征从任意维度线性映射到统一的128 维隐藏维度，为后续的残差块提供稳定的特征基础。

而残差连接作为深层网络训练中的经典结构，我将 LayerNorm归一化、GELU 激活、Dropout 正则化封装为可复用的残差块，作为整个网络的基本构建单元。

此外，分类头将主干网络输出的共享表示向量进一步压缩为32 维的特征，由线性层输出一个原始概率值。

模型采用的损失函数为基于带正类权重的二元交叉熵损失。正类权重的作用是当样本为正类时，对应的损失项被放大若干倍，可使正类样本的梯度贡献与负类大致持平。

在训练策略设计部分

学习率调度采用 Cosine Warmup 策略，前 5 个 epoch 的学习率从一个很小的初始值线性增长到设定值，之后进行余弦退火，学习率按照余弦曲线平滑下降至最小值 10的负6次方，避免训练初期参数更新受到局部噪声影响。

为避免模型在训练后期对训练集持续过拟合，我采用了 早停 策略，早停的监控指标设置为 AUC

在每个 epoch 完成验证集评估后，模型不直接使用 0.5 作为固定的分类阈值，而是在 200 个候选阈值中，逐一计算各阈值下的 各项指标得分，选择F-beta 得分最高的阈值。同时设置了最低召回率约束为 0.830，要求所选阈值尽量满足"召回率不低于 0.83"的下限。

在消融实验与性能评估部分

为了量化加权损失函数与自动阈值搜索对模型性能的贡献，以及探究不同网络深度和宽度对模型性能的影响，我设置了类别不平衡消融实验和网络结构消融实验，最终结果显示本系统的模型和训练策略设计都能够较为明显地改善性能。

本模型最终评估结果为：

模型 的AUC 为 0.9604。可以看到，模型在无理赔类别上表现优秀；同时，在有理赔类别上，召回率达到 0.83，精确率约为 0.73，说明模型在尽可能捕获高风险保单的同时，也保持了可接受的误报水平。

Slide 4: 系统实现

系统从功能上可以划分为四个核心业务模块。

第一个模块是用户与权限

系统实现了注册、登录和角色区分机制。

在系统中区分两种角色：**普通用户和管理员**。普通用户只能访问自己创建的数据。管理员则具备全量数据访问权限，并且独有模型训练和用户管理功能。

第二个模块是保单与车辆

保单信息管理是本系统的核心业务模块。每个保单拥有系统自动生成的唯一保单编号 ID

车辆信息管理模块维护与保单关联的车辆基础信息，包括车辆类型、注册年份等十种属性。

保单分析模块提供了多维度的数据可视化功能。分析目标涵盖风险类型、地区等八个保单属性；图表类型支持柱状图、折线图和饼图三种

第三个模块是理赔与统计

理赔记录管理模块维护七种理赔属性，包括索赔成本、本年度索赔次数等。

虽然理赔分析模块与保单分析模块功能类似，但统计指标更换为与理赔更加相关的指标，例如理赔记录数、总赔付金额等

这里需要重点说明的是，保单信息、车辆信息与理赔记录这三大管理模块之间通过统一的保单编号 ID 进行外键关联。在实际业务流程中，完全新增一份保单时存在先后顺序：操作员需要先在保单信息管理模块中新建保单并获取系统自动生成的保单编号，然后才能在车辆信息管理和理赔记录管理模块中对这个保单编号补充相应的车辆数据和理赔数据。

最后一个模块是预测与记录

理赔预测作为本系统的辅助功能模块。用户可以通过两种方式发起预测：一是选择系统中已存在的保单；二是手动逐一填写所有特征值进行预测。

每次预测完成后，系统会为预测结果生成简要的单特征局部消融解释，以自然语言的形式展示给用户，帮助业务人员理解模型为什么会给出这样的预测结果。

所有预测结果均持久化保存到 数据库表中

预测记录统计功能中提供三项核心统计指标，分别是历史预测总数、平均理赔概率、阳性预测占比，以及风险等级分布图和理赔概率分布图，帮助用户从整体上掌握预测数据的分布特征。

模型训练功能仅对管理员开放。在训练界面中，管理员可以设置多种超参数，以及设置模型每一层隐藏层的维数

此外，还设有系统首页，其中包含三个核心业务数据与快捷入口，对于普通用户，首页还会额外展示待办事项清单，其中列出了当前用户创建的数据中有哪些保单存在信息残缺

Slide 5: 创新、难点

创新点一

在于引入残差连接作为基本的网络构建单元，以及设计沙漏型的宽度变化结构——即先扩展、再深化、后压缩、再精炼。这种结构与传统的每层等宽设计相比，能够在控制参数量的前提下获得更强的非线性表达能力。

创新点二在于启用了业务导向的自动阈值搜索

在车险理赔场景中，“漏判高风险保单”的代价远高于“误报正常保单”的代价。

这种设计将模型的“排序能力”与业务的“判定规则”分离开来：模型本身负责输出准确的理赔概率排序，而最终的正负类划分规则由验证集上的阈值搜索确定。

创新点三在于体现了基于特征归因的可解释性

通常业务人员难以理解模型为什么会给出某个预测结果。本系统为此设计了单特征局部消融解释方法但也存在以下难点：

首先就是正负样本不均衡

在车险理赔数据中，实际发生理赔的保单只占少数。

我采用了四层递进的对策来解决这个问题：

在数据划分阶段使用**分层抽样**，在损失函数层面设置 **pos_weight=3.10** 的加权 BCE 损失，并引入**标签平滑**。最后通过**自动阈值搜索**校正决策边界的偏移。

其次是日期字段神经网络无法直接处理

原始数据集中包含五个以字符串形式存储的日期字段

我的处理方法是设计一个统一的“参考日期锚点”处理框架。使用锚点而非系统当前日期作为基准的好处是：无论何时运行代码，特征值保持完全一致，满足机器学习实验的可复现性要求。

结尾

（接下来展示系统演示视频）

以上就是我的毕业设计汇报的全部内容。谢谢各位老师